

Entrega 2: Modelo de Regresión Lineal para Predecir el de Venta de Apartamentos

Modelos de Análisis Estadísticos

Grupo 4:

Ana Sofía Bermúdez Moreno

Escarlet J. Valerio De Jesús

Guido Alejandro Jacome Hernández

Joaquín Rodríguez Villegas

1. Contexto general

En este informe se encuentra el desarrollo de un modelo de regresión lineal múltiple para predecir el precio de venta (SalePrice) de apartamentos de la inmobiliaria CasaRoble. Partimos de un conjunto de entrenamiento con 4,124 observaciones y 30 variables –tanto numéricas como categóricas– que describen características del inmueble, del edificio y del entorno. El trabajo se encuentra trackeado en el repositorio GitHub:

https://github.com/joaquinrovi/entrega_proyecto_MIAD_modelos_estadisticos.git

El desarrollo del modelo comprendió la selección de variables, evaluación de colinealidad, especificación funcional, estimación mediante MCO, validación de supuestos, evaluación del ajuste e interpretación de los coeficientes.

La ejecución del modelo está en la sección notebooks/Proyecto Regresión R Grupo4.ipynb. Las iteraciones y submissions a Kaggle están en notebooks/iteraciones Proyecto Regresión R Grupo4.

2. Selección de variables del modelo

Antes de ajustar cualquier modelo, revisamos si había colinealidad exacta o severa entre los 28 predictores disponibles (ya sin contar la columna índice).

a. Colinealidad exacta

Verificamos aritméticamente que dos variables son la suma exacta de sus componentes:

- $N_FacilitiesNearBy.Total.$ = suma de sus 6 componentes (oficinas, hospital, centro comercial, mall, ETC, parque).
- $N_SchoolNearBy.Total.$ = suma de sus 4 componentes (primaria, secundaria, bachillerato, universidad).

Al intentar ajustar el modelo completo con $lm(SalePrice \sim .)$, la función `vif()` nos arrojó el error “there are aliased coefficients in the model”, y con `alias()` confirmamos que, aparte de los dos totales, tres variables más ($N_SchoolNearBy.High.$, $N_SchoolNearBy.University.$ y $N_FacilitiesInApt$) eran combinaciones lineales exactas del resto de predictores. Esto ocurre porque las variables de facilidades y colegios cercanos quedan determinadas por la ubicación del edificio (`SubwayStation`). Estas cinco variables, junto con `SubwayStation`, se retiraron del modelo porque producen un sistema de ecuaciones normales sin solución única.

b. Colinealidad severa: eliminación iterativa por VIF

Una vez libre de dependencias exactas, el VIF todavía mostraba valores extremos (hasta 307,045 para $N_Parkinglot.Basement.$). Aplicamos un procedimiento iterativo: en cada paso eliminamos la

variable con mayor VIF y recalculamos, hasta que todas quedaron por debajo de 10 (criterio convencional en la literatura). Las variables eliminadas fueron:

Variable eliminada	VIF al momento de eliminarla
N_Parkinglot.Basement.	307,045.1
N_manager	368.5
N_elevators	155.0
N_FacilitiesNearBy.Dpartmentstore.	56.7
HeatingType	24.7
N_FacilitiesNearBy.ETC.	17.6
YearBuilt	13.8

El modelo resultante (16 predictores) quedo con un VIF máximo de 5.5 y un R^2 ajustado = 0.8676 (frente a 0.8933 del modelo con toda la colinealidad, una reducción esperable al quitar información redundante).

c. Prueba F parcial: eliminación de variables no significativas

Tres variables sobrevivieron al filtro de VIF, pero no resultaron individualmente significativas: N_FacilitiesNearBy.Mall., N_FacilitiesNearBy.Park. y N_SchoolNearBy.Middle.. Contrastamos formalmente su aporte conjunto con una prueba F parcial:

- H_0 : los coeficientes de las tres variables son conjuntamente cero.
- Resultado: $F = 0.766$, $p = 0.513$. No se rechaza H_0 : las tres variables se eliminan sin perdida significativa de ajuste (R^2 ajustado se mantuvo en 0.8676).

El modelo final queda con 13 variables predictores, todos con $VIF < 4$. La tabla completa está en el notebook Proyecto_Regresion_R_Grupo4.ipynb.

3. Determinación de la Estructura del Modelo

Con el conjunto de variables ya depurado, evaluamos si la forma funcional lineal era adecuada. Para esto usamos los gráficos de diagnóstico estándar de R y una curva de suavizado (loess) entre Size.sqf. y SalePrice.

La curva loess mostro una relación de rendimientos decrecientes: el precio sube con fuerza en apartamentos pequeños y se aplana –e incluso baja un poco– en los más grandes. Ese patrón no es compatible con un efecto lineal constante.

a. Incorporación de curvatura

Agregamos el termino cuadrático (Size.sqf.²) al modelo. La mejora fue grande y altamente significativa:

Modelo	R^2 ajustado	Prueba F vs. anterior
Base (13 predictores, lineal)	0.8676	–
+ Size.sqf. ²	0.8866	$F = 718.1$, $p \approx 2.3 \times 10^{-145}$

b. Interaccion Size.sqf. x HallwayType

El análisis de residuos sugirió que la pendiente de Size.sqf. cambia según el tipo de pasillo del edificio. Incluimos la interacción y la validamos con otra prueba F anidada:

Modelo	R^2 ajustado	Prueba F vs. anterior
+ Size.sqf. ²	0.8866	—
+ Size.sqf.:HallwayType	0.8964	F = 186.4, p $\approx 4.6 \times 10^{-78}$

c. Observaciones influyentes

Identificamos tres observaciones con residuos extremos (filas 331, 2643 y 681 del conjunto de entrenamiento), que corresponden a apartamentos con combinaciones atípicas pero plausibles de piso muy alto y tamaño pequeño (por ejemplo, un apartamento de 868 sqf en el piso 26). La distancia de Cook confirmó que ninguna domina el ajuste (D máximo = 0.009, muy por debajo del umbral de 1.0); 206 de 3,932 observaciones (5.2%) superan el umbral de referencia $4/n$, una proporción típica que no requiere intervención. Documentamos estas observaciones como limitación, pero no las eliminamos.

El modelo final de esta sección tiene 21 predictores (13 originales + Size.sqf.² + 2 términos de interacción con HallwayType).

4. Estimación de los Parámetros del Modelo


Estimamos los parámetros por mínimos cuadrados ordinarios (OLS) sobre las 3,932 observaciones de entrenamiento (después de eliminar 192 duplicados exactos). La siguiente tabla muestra los coeficientes más relevantes; la tabla completa de 22 coeficientes está en el notebook Proyecto_Regresion_R_Grupo4.ipynb.

Variable	Coeficiente ($\hat{\beta}$)	Error estándar	t
Intercepto	-27,690,000	420,000	-65.89
YrSold	13,750	209	65.90
Size.sqf.	344.24	11.66	29.52
Size.sqf. ²	-0.098	0.004	-25.48
Floor	1,200.67	77.16	15.56
N_Parkinglot.Ground.	-141.46	4.71	-30.04
AptManageType (self_mgmt.)	-59,800	3,416	-17.50

Todos los coeficientes reportados son significativos al 1% ($|t| > 2.5$, $p < 0.01$), salvo algunas categorías específicas de TimeToSubway y HallwayType, que discutimos en la sección de pruebas de hipótesis.

5. Verificación de los Supuestos del Modelo

Evaluamos los cuatro supuestos clásicos de la regresión lineal: linealidad, homocedasticidad, normalidad e independencia de los residuos.



a. Linealidad y homocedasticidad

La grafica de Residuos vs. Valores Ajustados muestra una curva de suavizado razonablemente plana, lo que respalda el supuesto de linealidad una vez incorporado el termino cuadrático de Size.sqf . Sin embargo, tanto esa grafica como la de Scale-Location muestran que el abanico de residuos se ensancha conforme aumentan los valores ajustados, lo cual es señal de heterocedasticidad. Lo confirmamos con la prueba de Breusch-Pagan:

$$BP = 669.13, \quad g.l. = 21, \quad p < 2.2 \times 10^{-16}$$

Se rechaza la hipótesis nula de homocedasticidad. Documentamos esta violación como una limitación conocida: los estimadores OLS siguen siendo insesgados, pero no son de varianza mínima, así que los errores estándar reportados podrían subestimar la incertidumbre real. Descartamos corregir con transformación logarítmica de la respuesta porque en validación cruzada esa transformación empeoraba el error de predicción del modelo.

b. Normalidad

El grafico Q-Q muestra que la masa central de los residuos se ajusta bien a la distribución normal, con desviación solo en las colas —asociada a las observaciones atípicas que identificamos en la sección de estructura (filas 331, 2643 y 681). La prueba de Shapiro-Wilk sobre todos los residuos ($n = 3,932$) arroja:

$$W = 0.9914, \quad p < 2.2 \times 10^{-16}$$

Aunque el test rechaza la normalidad, este resultado es esperable en muestras grandes, donde la prueba se vuelve extremadamente sensible a desviaciones mínimas sin relevancia práctica. El valor de W, muy cercano a 1, respalda una normalidad aproximada que consideramos suficiente.

c. Independencia

La prueba de Durbin-Watson sobre el orden original de los datos arroja:

$$DW = 1.091, \quad p < 2.2 \times 10^{-16} \text{ (autocorrelacion positiva)}$$

Como los datos son de corte transversal y no una serie de tiempo, investigamos si este resultado reflejaba una verdadera dependencia temporal o una estructura de agrupamiento (clustering) por edificio que el modelo no captura. Al reordenar las observaciones según variables proxy de “mismo edificio” (N_APT y N_Parkinglot.Ground.) y repetir la prueba, el estadístico empeoró (DW = 0.683). Eso descarta la interpretación temporal y confirma que se trata de estructura espacial no modelada –consistente con haber tenido que excluir SubwayStation por colinealidad exacta. Lo documentamos como limitación: el supuesto de independencia se viola por agrupamiento geográfico, no por autocorrelación en el tiempo.

d. Resumen

Supuesto	Resultado	Veredicto
Linealidad	Curva de residuos casi plana tras Size.sqf. ²	Razonable
Homocedasticidad	BP = 669.13, $p < 2.2 \times 10^{-16}$	Se viola; OLS insesgado, no eficiente
Normalidad	W = 0.991; Q-Q recto salvo colas	Aproximada
Independencia	DW = 1.09; empeora por proxy de edificio	Se viola; clustering espacial

6. Determinación de la Bondad de Ajuste del Modelo

El modelo explica cerca del 90% de la variabilidad observada en SalePrice. El estadístico F global es altamente significativo, lo que confirma que el conjunto de predictores aporta un poder explicativo muy superior al de un modelo solo con intercepto.

Métrica	Valor
R^2	0.8970
R^2 ajustado	0.8964
Error estándar residual	34,210 (USD)
Estadístico F (global)	1,620.7 en (21, 3,910) g.l., $p < 2.2 \times 10^{-16}$
AIC	93,284
BIC	93,428

7. Cálculo de Intervalos de Confianza para los Parámetros del Modelo

Calculamos los intervalos de confianza al 95% para cada coeficiente del modelo final. La siguiente tabla presenta los intervalos de las variables numéricas principales.

Variable	Límite inferior (2.5%)	Límite superior (97.5%)
YrSold	13,343	14,161
Size.sqf.	321.38	367.11
Size.sqf. ²	-0.106	-0.091
Floor	1,049.39	1,351.96
N_Parkinglot.Ground.	-150.70	-132.23
TimeToSubway (10-15min)	-8,084	2,467

Vale la pena notar el intervalo de TimeToSubway (10-15min), que cruza el cero: es consistente con que esa categoría específica no resulto individualmente significativa en la prueba t, aunque el factor TimeToSubway en su conjunto si aporta al modelo.

8. Prueba de Hipótesis sobre los Parámetros del Modelo

a. Pruebas individuales (t-test)

Para cada coeficiente β_i contrastamos $H_0: \beta_i = 0$ frente a $H_1: \beta_i \neq 0$. De los 22 coeficientes del modelo, 19 resultaron significativos al 5% (incluyendo el 100% de las variables numéricas y la mayoría de las categorías de los factores). Las excepciones fueron TimeToSubway (10-15min) con $p = 0.297$ y la interacción Size.sqf. : HallwayType_mixed con $p = 0.532$.

b. Prueba conjunta (F parcial) por factor

Que una categoría individual no sea significativa no implica que el factor completo sea irrelevante. Para aclarar esto, contrastamos formalmente la hipótesis conjunta para TimeToSubway:

- H_0 : los cuatro coeficientes de TimeToSubway son conjuntamente cero (el factor no aporta al modelo).
- Resultado: $F = 107.11$, $p \approx 1.0 \times 10^{-86}$. Se rechaza H_0 con contundencia.

Aunque una categoría específica no sea individualmente significativa, el factor TimeToSubway en su conjunto aporta información muy significativa al modelo, y se mantiene completo en la especificación final.

9. Interpretación de los Coeficientes del Modelo

a. Variables numéricas:

- **YrSold** ($\hat{\beta} = 13,750$): cada año adicional de venta se asocia con un incremento de aproximadamente \$13,750 en el precio. Esto refleja la apreciación general del mercado inmobiliario en el periodo observado.
- **MonthSold** ($\beta=1.777$): efecto estacional leve, ~\$1.777 más por cada mes de avance dentro del año.
- **Floor** ($\hat{\beta} = 1,201$): cada piso adicional agrega aproximadamente \$1,201 al precio, manteniendo todo lo demás constante.
- **N_Parkinglot.Ground.** ($\hat{\beta} = -141.5$): cada parqueadero de superficie adicional se asocia con una reducción de aproximadamente \$141.5. El signo parece contraintuitivo, pero

probablemente se debe a que más parqueaderos de superficie (en vez de subterráneos) es típico de desarrollos más antiguos o de menor categoría.

- **N_APT** ($\beta=4.691$): cada apartamento adicional en el conjunto suma ~\$4.691, asociado a mayor escala/infraestructura del complejo.
- **N_FacilitiesNearBy.PublicOffice.** ($\beta=3.315$) y **N_FacilitiesNearBy.Hospital.** ($\beta=10.650$): más oficinas públicas y hospitales cercanos se asocian positivamente con el precio (proximidad a servicios).
- **N_SchoolNearBy.Elementary.** ($\hat{\beta} = -22,810$): más colegios de primaria cercanos se asocia con menor precio, posiblemente porque esas zonas corresponden a áreas residenciales más periféricas.

b. Curvatura: Size.sqf. y Size.sqf.^2

Al incluir el termino lineal ($\hat{\beta} = 344.24$) y el cuadrático ($\hat{\beta} = -0.098$), el efecto marginal del tamaño no es constante sino decreciente:

$$\frac{\partial \text{SalePrice}}{\partial \text{Size.sqf.}} = 344.24 + 2 \times (-0.098) \times \text{Size.sqf.}$$

Por ejemplo, a 500 sqf el efecto marginal es de ~\$246 por sqf adicional, mientras que a 1,500 sqf baja a ~\$50 por sqf. Esto es coherente con lo que mostraba la curva loess.

c. Interacción Size.sqf. x HallwayType

El efecto marginal del tamaño depende del tipo de pasillo del edificio: en edificios tipo terraced, la pendiente adicional es de +\$79.63/sqf respecto a la categoría base (corridor); en edificios tipo mixed, la diferencia no es significativa ($p = 0.532$), así que no se distingue estadísticamente de corredor.

d. Variables categoricas

- **AptManageType** (self_management, $\hat{\beta} = -\$59,800$): los apartamentos con autogestion valen en promedio ~\$59,800 menos que los de gestión fiduciaria (*management_in_trust*), lo que sugiere que una administración profesional se asocia con mayor valor percibido.
- **TimeToSubway**: el patrón no es monotónico con la distancia –la categoría 15-20min presenta el mayor efecto relativo (+\$67,390)–. Esto probablemente se debe a que ciertas distancias específicas coinciden con zonas de mayor valor por otras razones (composición del vecindario), y no a un efecto causal puro de la distancia al metro. Lo documentamos como hallazgo asociativo, no causal.

10. Modelos alternativos Kaggle

El modelo que presentamos en este informe (v1) fue depurado deliberadamente por colinealidad (VIF) para poder interpretar los coeficientes y evaluar los supuestos de manera rigurosa. Sin embargo, la colinealidad afecta la varianza de los estimadores, no la capacidad predictiva del modelo en si.

Para la competencia de Kaggle (donde el criterio de evaluación es el MSE), desarrollamos una segunda especificación que conserva todas las variables predictivas –incluidas las colineales y SubwayStation–, retirando únicamente los dos totales exactos. Además, agregamos interacciones

adicionales de Size.sqf. con HallwayType, TimeToBusStop, TimeToSubway y SubwayStation, seleccionadas por validación cruzada.

Este modelo alternativo redujo el MSE de la competencia de 1,063,214,600 (RMSE $\approx$ \$32,608, primera entrega) a 794,966,822 (RMSE $\approx$ \$28,196), una mejora de aproximadamente 25%. Las conclusiones interpretativas del modelo reportado en las secciones anteriores no cambian. El detalle completo de ambas especificaciones, su código en R y las validaciones cruzadas están documentados en los notebooks anexos del repositorio.

11. Conclusiones

El modelo de regresión lineal múltiple que construimos logra explicar cerca del 90% de la variabilidad en el precio de venta de los apartamentos (R^2 ajustado = 0.8964), usando 13 predictores libres de colinealidad severa. El tamaño del apartamento resultó ser el factor más determinante del precio, pero con rendimientos decrecientes que solo pudimos capturar al incluir el término cuadrático y la interacción con el tipo de pasillo. En cuanto a los supuestos, el modelo presenta dos violaciones que documentamos con honestidad: heterocedasticidad y agrupamiento espacial en los residuos, ambas consecuencias de la naturaleza de la data set –precios de vivienda con alta variabilidad en el segmento más caro y datos agrupados por edificio–. Estas limitaciones no invalidan las estimaciones puntuales de los coeficientes (OLS sigue siendo insesgado), pero sí implican que los errores estándar y, por tanto, los intervalos de confianza reportados deben interpretarse con cautela. Finalmente, la experiencia de desarrollar en paralelo un modelo interpretable (v1) y uno predictivo (Kaggle) nos permitió ver en la práctica que la colinealidad deteriora la inferencia, pero no necesariamente la predicción: al reincorporar las variables colineales y agregar interacciones, el MSE bajó un 25% sin que cambiaran las conclusiones sustantivas del análisis.